- Super-Resolution Through Neighbor Embedding
- CVPR 2004, Hong Chang, 港科大

开启了 Learning-based 这一类超分方法的先河，当然现在回头看，太过简单、直白、朴素、粗糙了。

1. 有高清图片，对高清图片进行下采样，得到粗糙图片，这样就有（低清-高清）这样的映射作为训练集了
2. **直接开始预测，**按照块来预测，比如按照 5*5 的块：寻找低清训练图片有哪些块和它比较接近。接近的判断依据：备注1
3. 通过这些块，构建参数 W：【F(待预测低清图片的某一块) = W*F(训练集找的低清块)】，其中 F 表示提取特征。提取规则：备注2
   - 为什么不直接使用像素值：觉得这样误差大呗，实际上也可以将像素值作为一个特征，不过这样只有一种特征，不像现在的设定，有好几个特征
   - W 怎么求：实际上就是一个简单的优化方程，和 LLE 方法有点异曲同工，见图1，其中 x 就是提取完的特征块
4. 认为参数 W 在高清图中有用，预测像素值 = W*训练集中低清块对应的高清块，得到了预测出来的高清块
5. 每次移动低清块是有重叠的，最终结果是一个平均的结果，见图2

备注一

RGB 转为 YIQ，比较由 Y 组成的向量的欧式距离。

例：如果块大小为 $5*5$，则向量长度为 25，距离计算为：$\sqrt{(x_1-y_1)^2+\ldots+(x_{25}-y_{25})^2}$

备注二

特征提取分别是一阶梯度，二阶梯度，组成 4 个值。

例：如果块大小为 $5*5$，对于中间点，它的梯度分别为：$\nabla^1=\begin{bmatrix} z_{34}-z_{32} \\ z_{23}-z_{43} \end{bmatrix}$ $\nabla^2=\begin{bmatrix} z_{35}+z_{31}-2z_{33} \\ z_{13}+z_{53}-2z_{33} \end{bmatrix}$

图1

$$\mathcal{E}^q=\|\mathbf{x}_t^q-\sum_{\mathbf{x}_s^p\in\mathcal{N}_q} w_{qp}\mathbf{x}_s^p\|^2,$$

$$\mathbf{G}_q=(\mathbf{x}_t^q\mathbf{1}^T-\mathbf{X})^T(\mathbf{x}_t^q\mathbf{1}^T-\mathbf{X}),$$

$$\mathbf{w}_q=\frac{\mathbf{G}_q^{-1}\mathbf{1}}{\mathbf{1}^T\mathbf{G}_q^{-1}\mathbf{1}}.$$

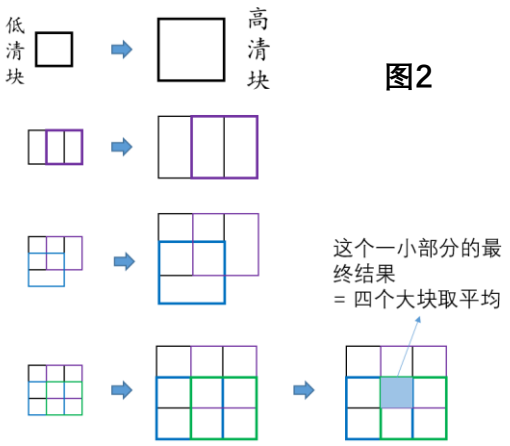

图2

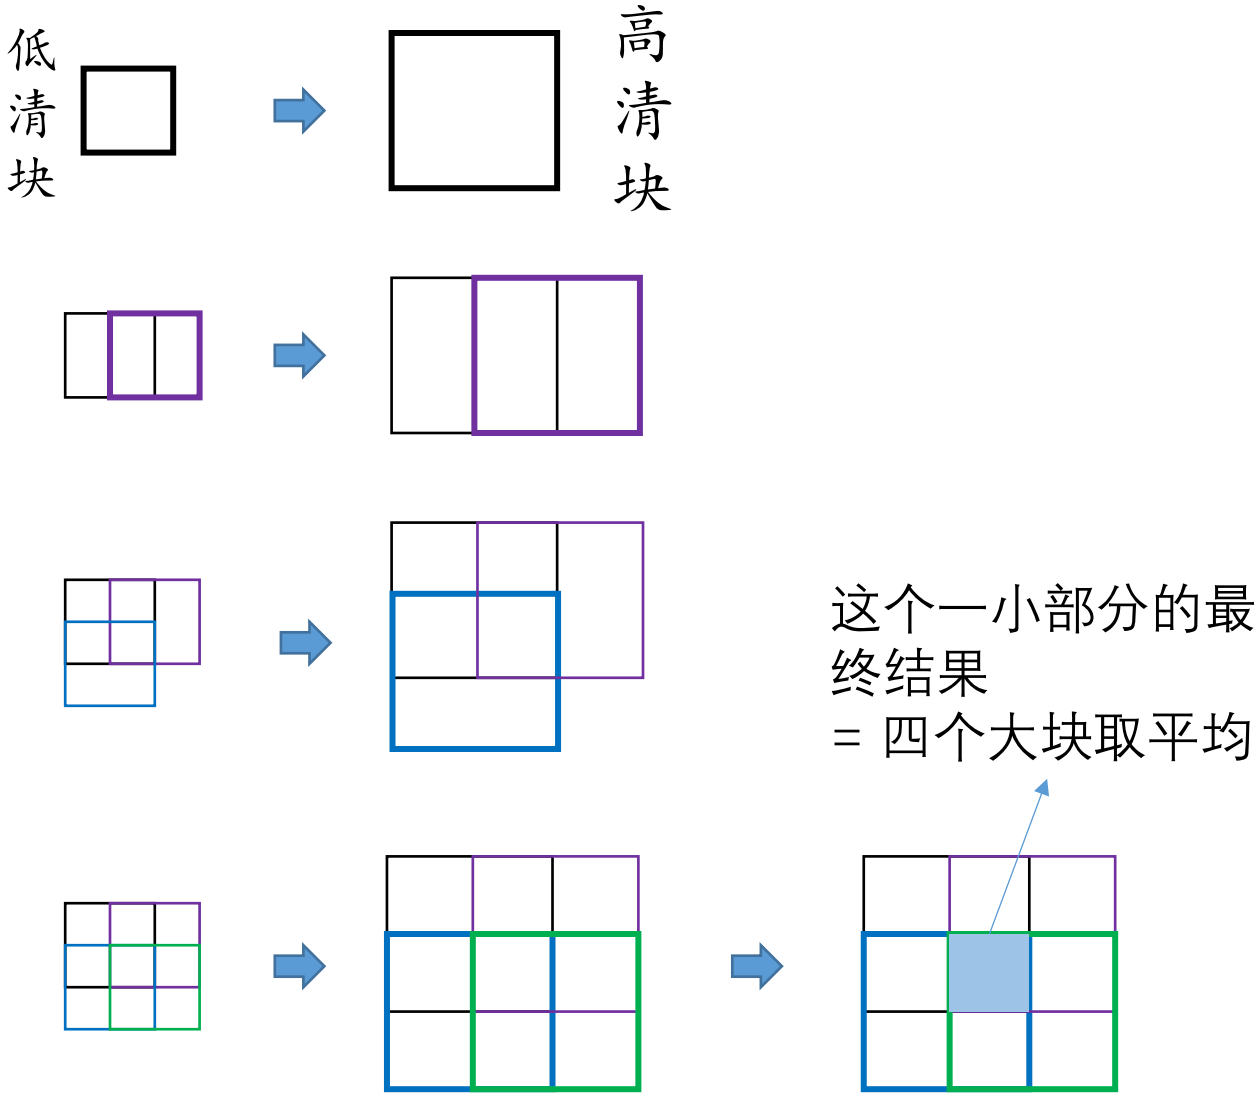
低清块
高清块
这个一小部分的最终结果
= 四个大块取平均